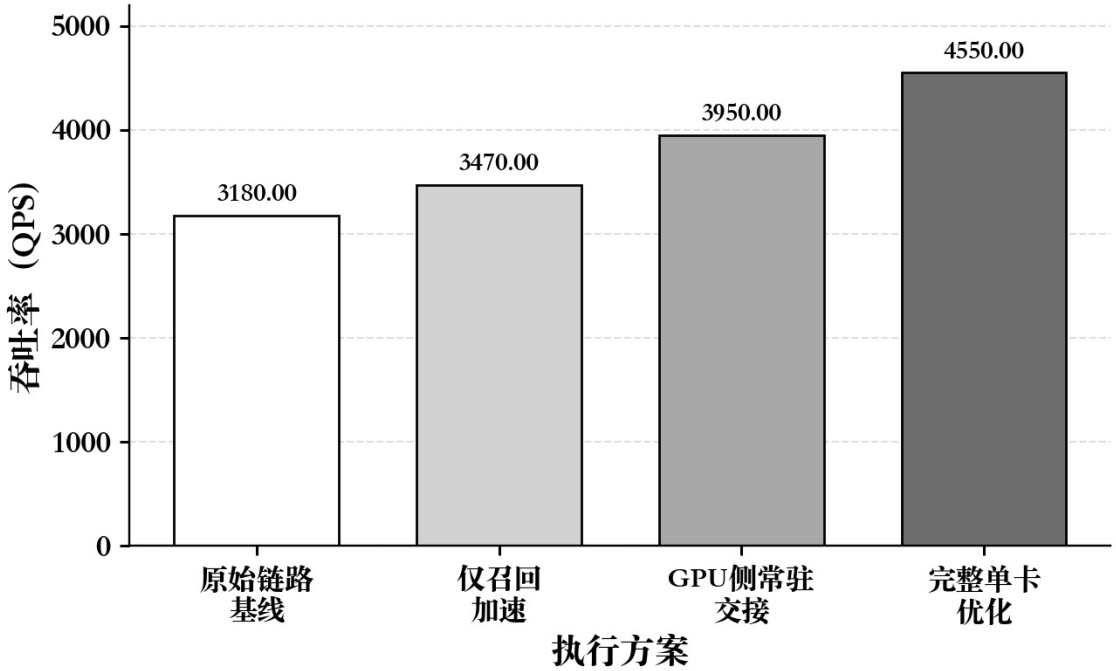
吞吐率（QPS）
5000
4000
3000
2000
1000
0
3180.00
3470.00
3950.00
4550.00
原始链路基线
仅召回加速
GPU侧常驻交接
完整单卡优化
执行方案

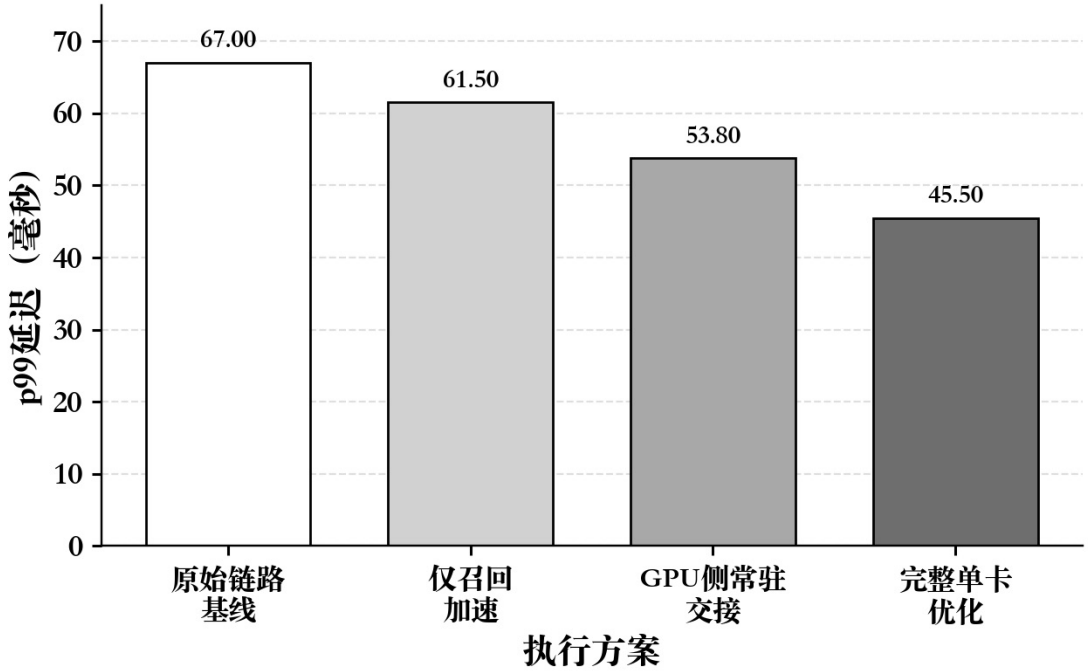
p99延迟（毫秒）
70
60
50
40
30
20
10
0
67.00
61.50
53.80
45.50
原始链路基线
仅召回加速
GPU侧常驻交接
完整单卡优化
执行方案

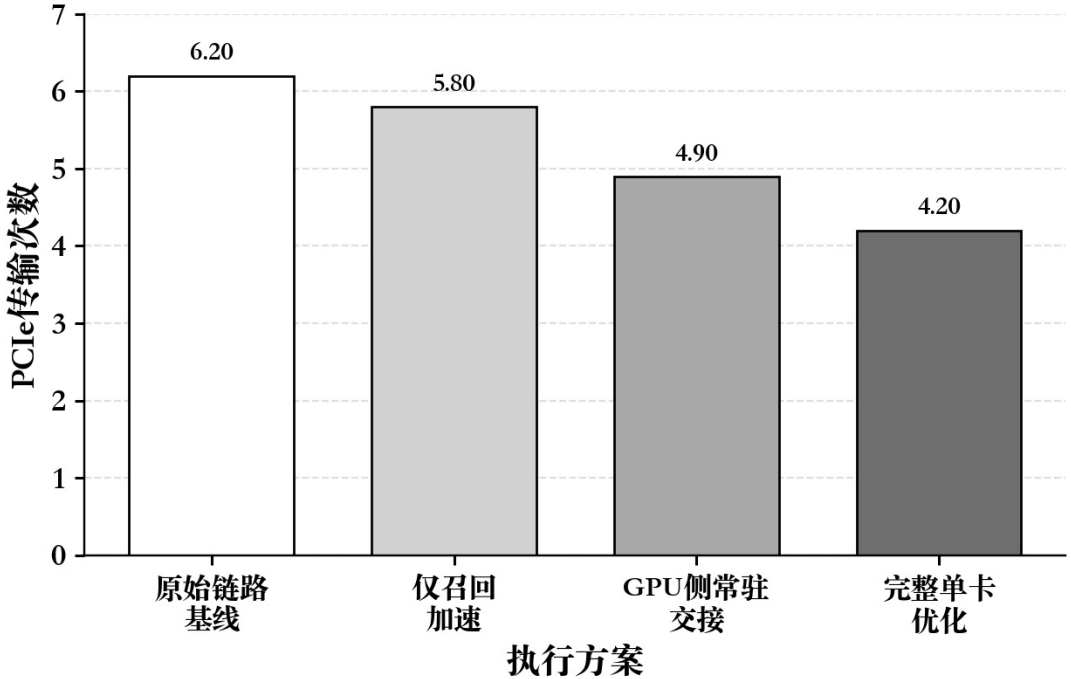
PCIe传输次数
7
6
5
4
3
2
1
0
6.20
5.80
4.90
4.20
原始链路基线
仅召回加速
GPU侧常驻交接
完整单卡优化
执行方案

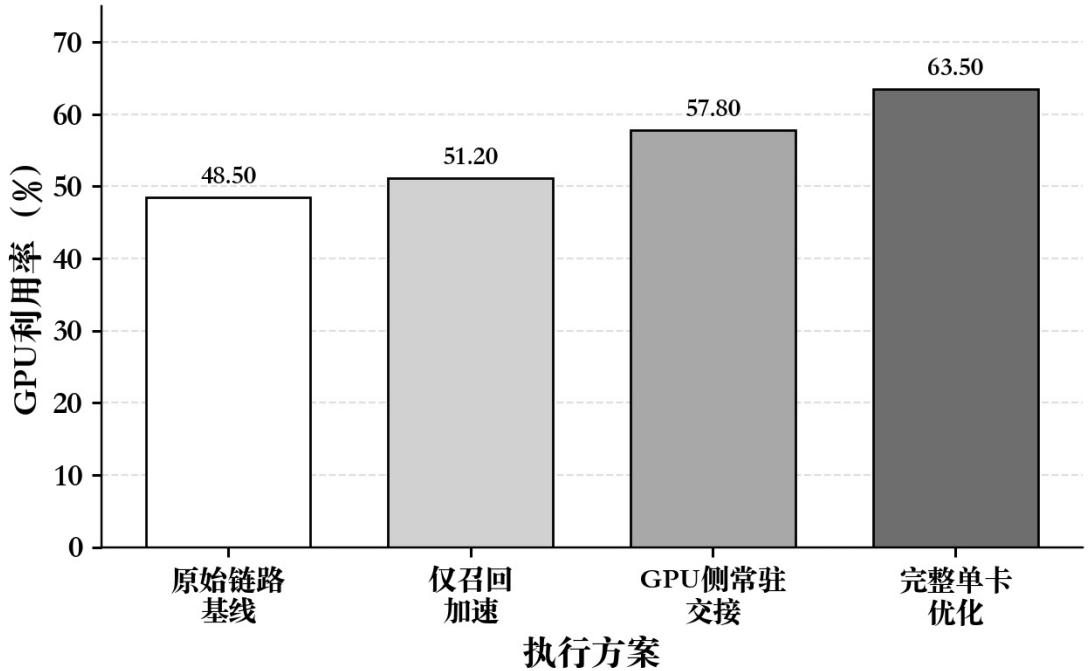
GPU利用率（%）
70
60
50
40
30
20
10
0
48.50
51.20
57.80
63.50
原始链路基线
仅召回加速
GPU侧常驻交接
完整单卡优化
执行方案