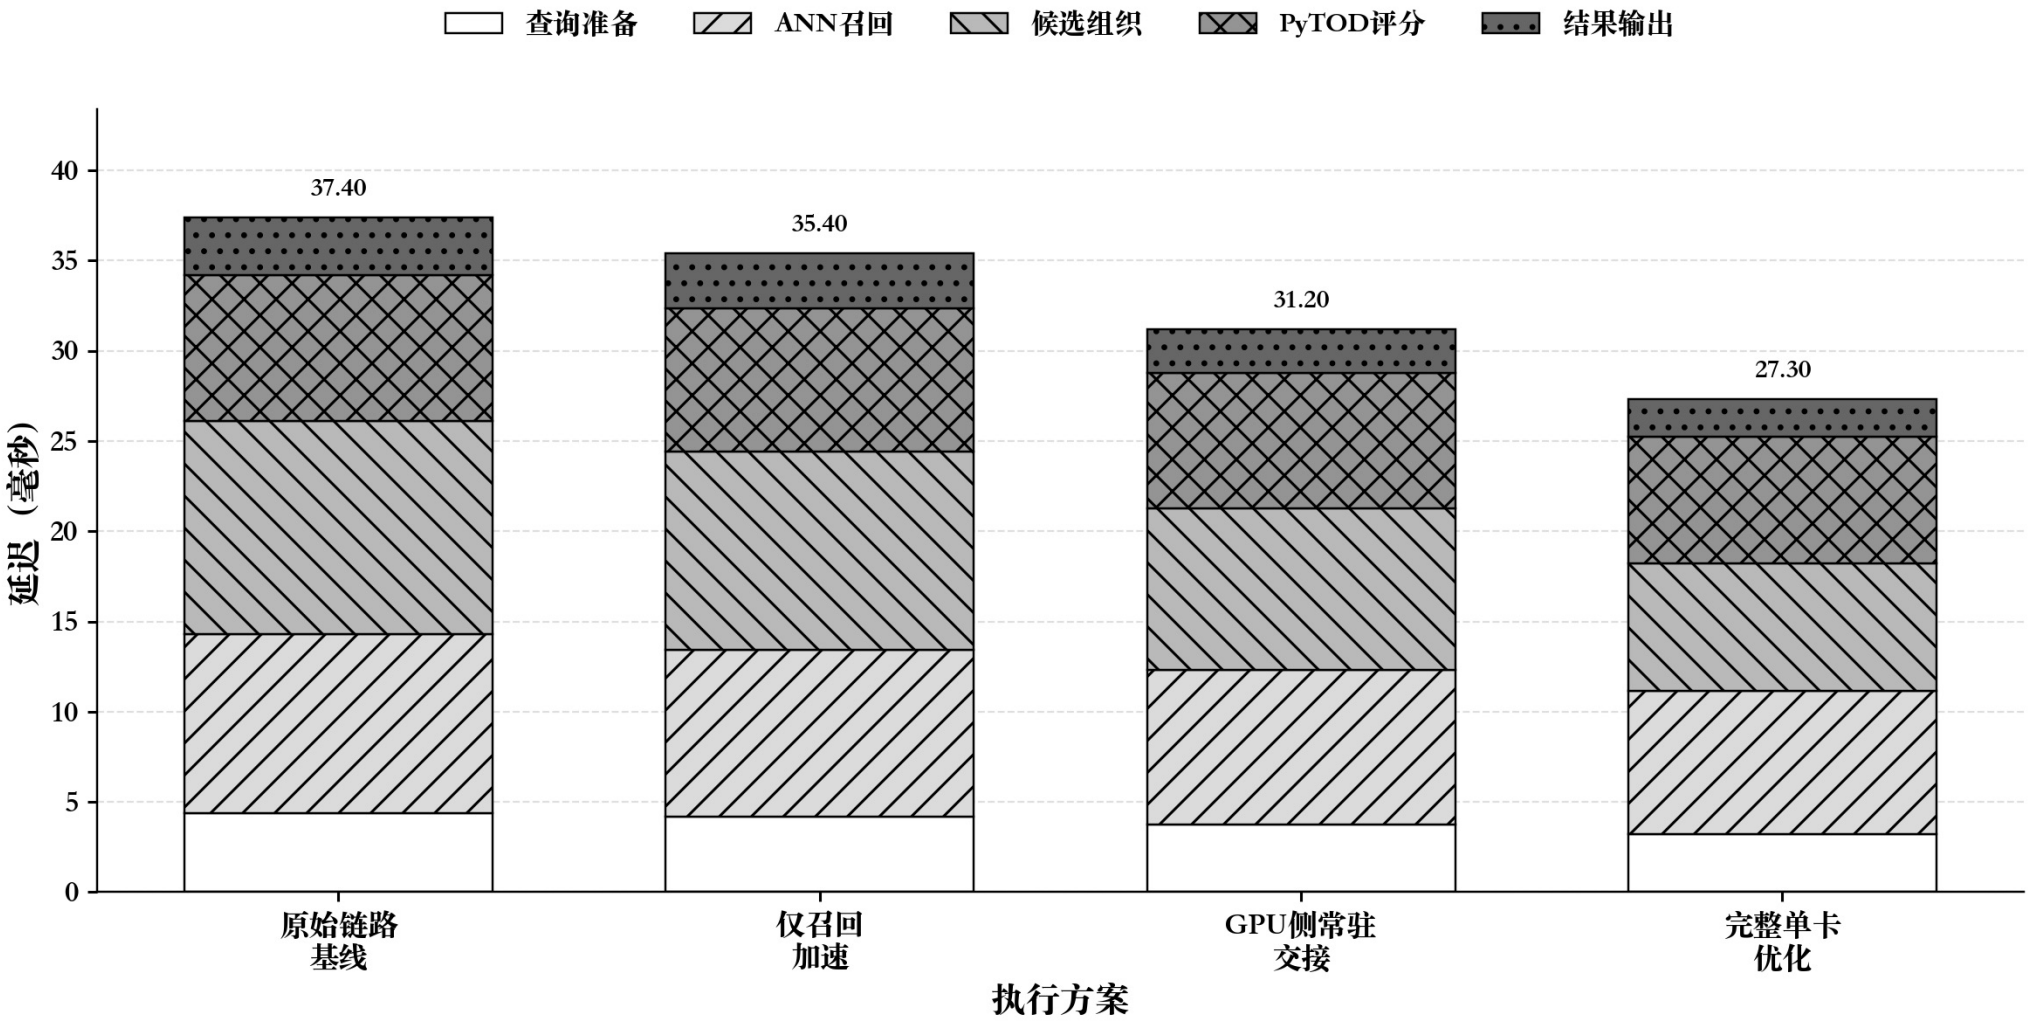
查询准备
ANN召回
候选组织
PyTOD评分
结果输出
延迟（毫秒）
0
5
10
15
20
25
30
35
40
37.40
35.40
31.20
27.30
原始链路
基线
仅召回
加速
GPU侧常驻
交接
完整单卡
优化
执行方案