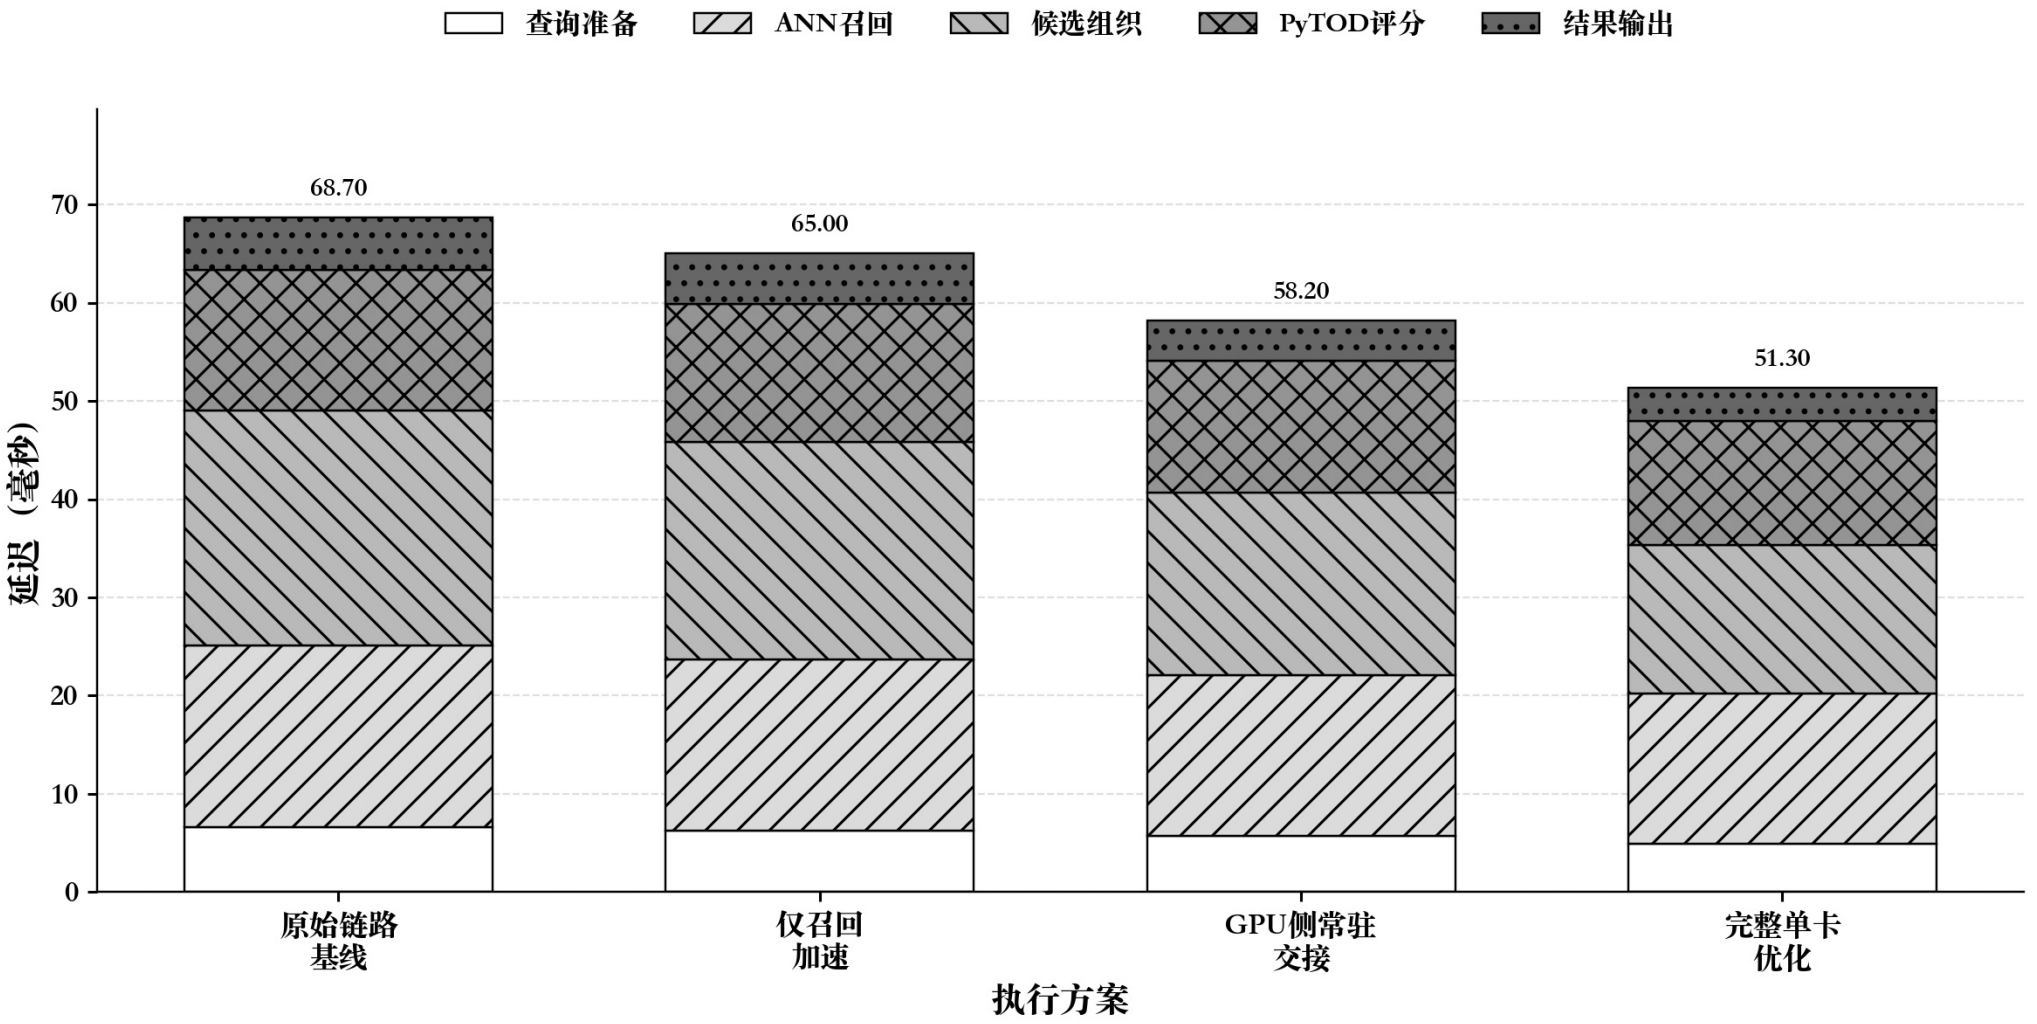
查询准备
ANN召回
候选组织
PyTOD评分
结果输出
延迟（毫秒）
0
10
20
30
40
50
60
70
68.70
65.00
58.20
51.30
原始链路
基线
仅召回
加速
GPU侧常驻
交接
完整单卡
优化
执行方案