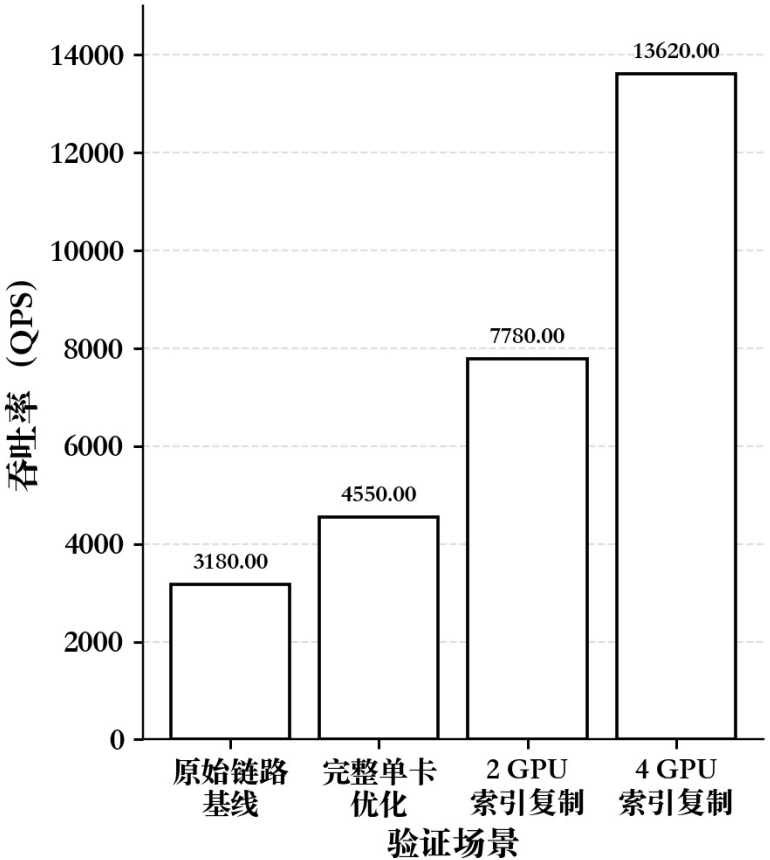
吞吐率（QPS）
14000
12000
10000
8000
6000
4000
2000
0
3180.00
4550.00
7780.00
13620.00
原始链路基线
完整单卡优化
2 GPU索引复制
4 GPU索引复制
验证场景

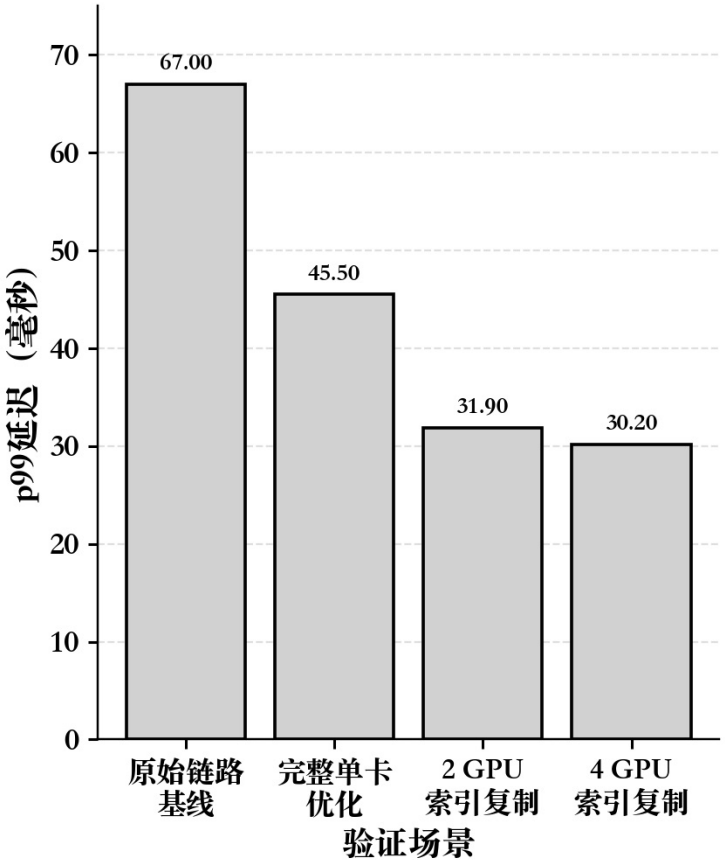
p99延迟（毫秒）
70
60
50
40
30
20
10
0
67.00
45.50
31.90
30.20
原始链路基线
完整单卡优化
2 GPU索引复制
4 GPU索引复制
验证场景

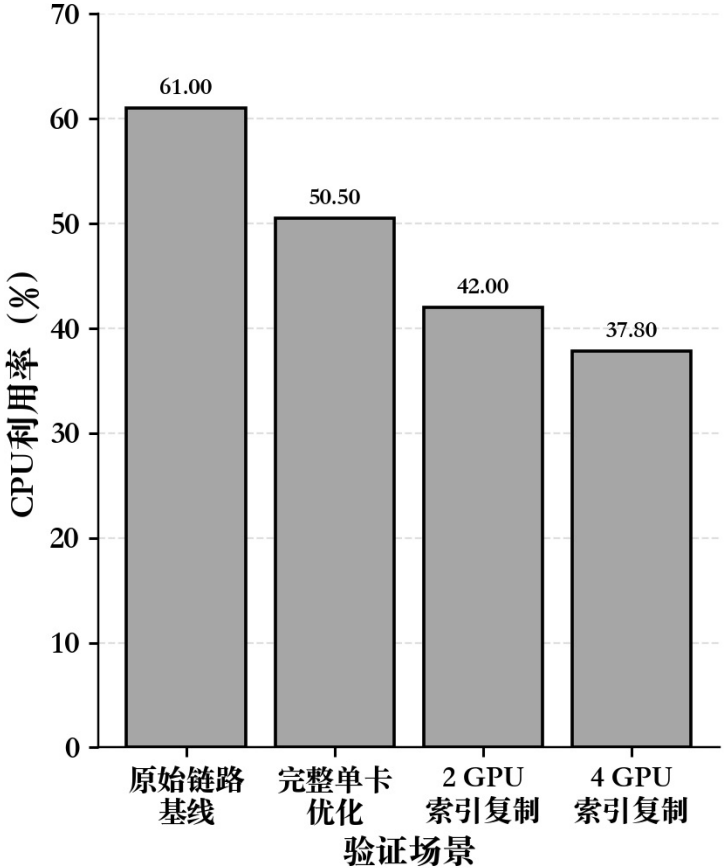
CPU利用率（%）
70
60
50
40
30
20
10
0
61.00
50.50
42.00
37.80
原始链路基线
完整单卡优化
2 GPU索引复制
4 GPU索引复制
验证场景